YOLO 기반 볼 배치 검사에서 잡음과 학습량에 따른 영상 전처리의 엄격 검출 성능 분석

Image Preprocessing for YOLO-Based Ball Inspection under Noise and Limited Training Data

요 약

본 논문은 볼 배치 검사에서 영상 전처리의 효과와 평가 지표의 차이를 분석한다. 500 장을 유사 영상 그룹 단위로 분리한 5 겹 교차검증을 수행하고 주요 조건을 3 개 시드로 반복하였다. 모든 볼의 누락・추가 검출이 없는 엄격 정확도는 잡음 표준편차 80 에서 가우시안 블러 적용 시 72.00%에서 94.13%로, 잡음 40 과 학습량 25%에서는 CLAHE 적용 시 39.80%에서 55.27%로 높아졌다. 반면 일반 영상의 개선은 시드에 따라 달랐다. 전처리의 이점은 조건에 의존하며, 높은 OK/NG 판정 일치율만으로 검출 신뢰성을 판단하기 어렵다.

Ⅰ. 서 론

볼의 개수와 배치를 검사하는 시스템에서는 검출 오류와 최종 판정 오류가 일치하지 않는다. 볼을 누락하거나 잘못 추가 검출해도 주석과 예측이 모두 NG 이면 이진 판정은 일치한다. 따라서 높은 판정 일치율이 정밀한 검출을 의미하는지 별도로 검토해야 한다.

본 연구는 YOLOv8n[1] 검출 결과에 영역별 개수 규칙을 적용하는 검사에서 전처리 효과를 평가한다. CLAHE[2]의 국소 대비 조정과 가우시안 블러의 평활화가 유리한 조건을 구분하고, 시드에 따른 순위 변동을 분석한다. 핵심 질문은 동일한 전처리가 잡음과 학습량이 다른 조건에서도 일관된 이점을 갖는가이다.

Abstract

This study evaluates preprocessing for YOLOv8n-based ball inspection using 500 images, five-fold cross-validation with near-duplicate groups kept together, and three seeds. Strict accuracy requires every annotated ball to be detected without extra detections. Gaussian blur improves this metric from 72.00% to 94.13% under Gaussian noise with a standard deviation of 80. CLAHE improves it from 39.80% to 55.27% with noise of 40 and 25% training data. Improvements on clean images vary across seeds. These results support condition-dependent preprocessing and show why agreement with annotation-derived OK/NG decisions alone is insufficient to assess detection reliability.

Key words: YOLOv8n, ball inspection, image preprocessing, strict accuracy

검출기 구조의 변경 없이 학습 조건을 통일하여 원영상과 단일 필터 10 종, 복합 필터 5 종을 탐색하였다. 이후 주요 후보를 반복 평가하였다. 본 논문은 단일 실행의 최고 성능보다 반복 결과의 변동성과 조건별 효과 차이를 중심으로 보고한다.

Ⅱ. 실험 방법

2.1 데이터와 판정 규칙

2,944×2,352 화소 회색조 영상 500 장과 볼 상자 주석을 사용하였다. 기존 train 400 장과 val 100 장을 재분할했으며 독립 test 자료는 없다. 원영상에서 국소 표준편차, Otsu 이진화 및 형태학 연산으로 부품 영역을 추정한다. 중심 기준 네 방향의 영역 내 볼 개수가 상・좌・하・우 각각 5・4・2・2 이면 OK 이다.

동일 규칙을 주석에 적용한 기준 판정은 OK 223 장, NG 277 장이다. 이는 현장 검사자가 독립 부여한 정답이 아니므로 결과를 주석 유도 판정과의 일치로 해석한다. 부품 검출 실패 13 장은 영상 중심과 전체 볼을 사용하는 대체 처리를 적용하였다.

2.2 그룹 분할과 학습 설정

128×128 축소영상 간 평균 절대차가 1 미만인 쌍을 연결하여 368 개 유사 영상 그룹을 구성하였다. 그룹을 통째로 외부 평가 폴드에 배정하는 5 겹 교차검증을 사용하였다. 폴드당 학습 359~361 장, 내부 검증 40 장, 평가 99~101 장이다. 평가 폴드와 나머지 자료 간 그룹 중복은 없으며, 각 영상은 해당 영상을 학습하지 않은 모델로 평가하였다.

필터마다 사전학습 YOLOv8n 을 별도로 미세조정하였다. 최대 30 epoch, 배치 8, 입력 크기 설정 1,280, 조기 종료 patience 15 를 공통 적용하였다. 상하・좌우 반전 확률 0.5, scale 0.3, translate 0.1, hsv_v 0.4 를 지정하고 그 외 증강은 라이브러리 기본값을 사용하였다. 추론 신뢰도는 0.25, NMS IoU 는 0.5 이다. RTX 4090 과 Ultralytics 8.4.160 을 사용하였다.

2.3 열화 조건과 전처리

8 비트 밝기에 영평균 가우시안 잡음을 더하고 [0,255]로 제한한 뒤 필터를 적용하였다. 학습・검증・평가 자료에 동일한 변환을 적용하므로, 학습 후 처음 접하는 열화에 대한 시험은 아니다. 조건은 일반 영상, 잡음 표준편차 80 과 전체 학습량, 잡음 40 과 학습량 25%이다. 마지막 조건의 학습 영상은 폴드당 약 90 장이다.

Kornia[3] 기반 CLAHE 는 clip limit 40, 격자 16×16 이며, 가우시안 블러는 표준편차 20 화소와 121×121 커널을 사용한다. 감마는 0.3 이다. 부품 영역은 모든 조건에서 원영상의 추정값을 유지하여 볼 검출 변화에 초점을 맞췄다.

2.4 평가 지표와 반복 분석

OK/NG 일치율은 주석 유도 판정과 예측 판정이 같은 영상의 비율이다. 엄격 정확도는 영상 전체에서 미검출과 추가 검출이 모두 0 인 영상의 비율이다. 주석 중심과 예측 중심의 거리가 주석 상자 긴 변의 0.5 배 이내인 후보를 거리순으로 일대일 대응한다. 이 지표는 IoU 기반 mAP 와 구별된다.

시드 42・43・44 마다 폴드, 내부 검증 분할, 학습 난수와 잡음 실현을 변경하였다. 각 시드의 전체 500 장 성능에 대해 평균과 표본 표준편차를 구했다. 원영상 대비 차이는 영상별 시드 평균 차이를 그룹 단위로 5,000 회 재표집한 95% 백분위 구간으로 요약하였다.

III. 실험 결과 및 고찰

3.1 일반 영상의 시드 의존성

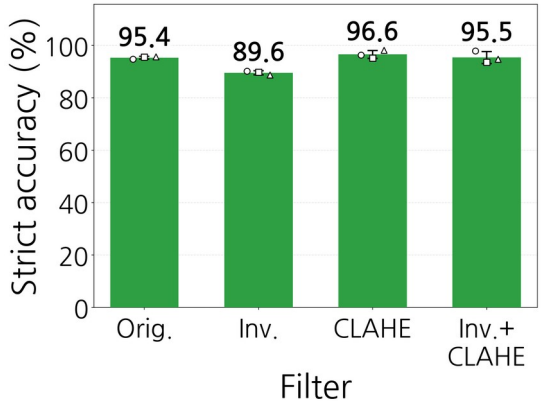


그림 1. 일반 영상의 엄격 정확도
Fig. 1. Strict accuracy on clean images

그림 1 의 막대는 평균, 오차막대는 표준편차, 점은 세 시드이다. 원영상은 95.40±0.53%, CLAHE 는 96.60±1.51%였으나 CLAHE 의 개선은 3 개 중 2 개 시드에서만 관찰되었다. 반전은 89.60±0.72%, 반전 후 CLAHE 는 95.47±2.27%였다. 복합 필터의 단일 시드 이득이 반복 평균에서는 유지되지 않아 최고 실행만으로 우월성을 주장하기 어렵다.

3.2 강한 잡음에서의 평활화 효과

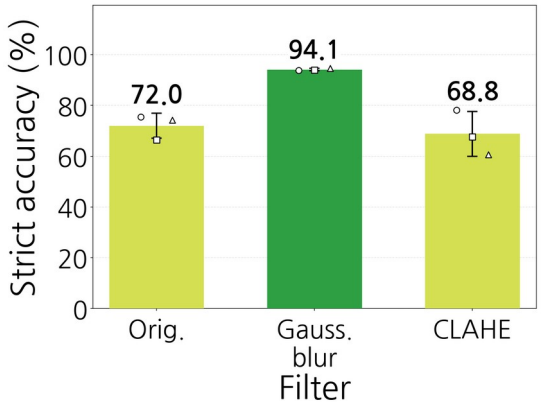


그림 2. 잡음 80 과 전체 학습량의 결과
Fig. 2. Noise SD 80 with full training data

그림 2 에서 원영상의 엄격 정확도는 72.00±4.89%, 가우시안 블러는 94.13±0.42%였다. 세 시드 모두 개선되었고 평균 차이는 22.13%p, 그룹 재표집 구간은 [19.09, 25.27]%p 였다. 반면 CLAHE 는 68.80±8.86%로 변동성이 컸다. 평활화의 잡음 완화와 일치하는 경향이지만, 실제 특징의 변화나 원인을 분리 측정한 결과는 아니다.

원영상과 가우시안 블러의 OK/NG 일치율은 각각 98.87%, 99.67%로 차이가 0.80%p 에 그쳤다. 엄격 정확도의 22.13%p 차이와 대비되며, 이진 판정이 같은 경우에 가려지는 검출 오류를 별도 지표로 확인할 필요가 있음을 보여준다.

3.3 잡음과 소량 학습의 복합 조건

그림 3 에서 원영상은 39.80±3.12%, CLAHE 는 55.27±5.74%였다. 세 시드 모두 개선되었으며 차이는 15.47%p, 재표집 구간은 [12.40, 18.53]%p 였다. 히스토그램 평활화와 감마 보정은 각각 43.87%, 44.40%였고, 가우시안 블러는 34.27±5.25%였다.

강한 잡음 조건에서 유리했던 블러가 이 조건에서도 유리하지는 않았다. 다만 두 조건은 잡음 강도와 학습량이 동시에 달라, 순위 변화의 원인을 학습량 감소 하나로 귀속할 수 없다. 잡음과 학습량의 완전 요인 실험이 후속 검증에 필요하다.

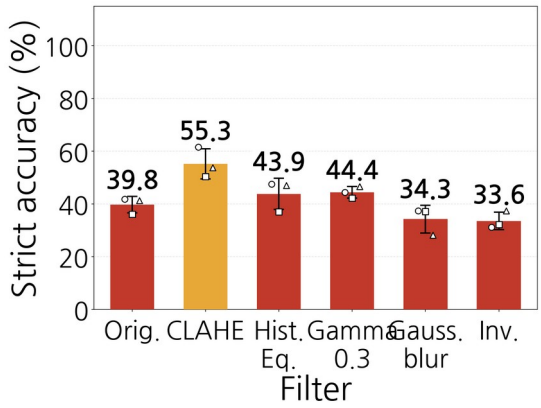


그림 3. 잡음 40 과 학습량 25%의 결과
Fig. 3. Noise SD 40 with 25% training data

3.4 해석 범위와 검증 한계

이 결과는 동일 자료에서 후보를 탐색한 뒤 반복한 탐색적 비교이다. 재표집 구간은 관측된 세 시드의 예측에 조건부이며, 전체 학습 불확실성과 다중 비교를 보정한 구간은 아니다. 외부 평가 그룹은 분리했으나 내부 학습・검증 사이에는 9~20 개 그룹이 겹쳐 모델 선택의 독립성에도 한계가 있다.

부품 영역을 원영상에서 고정했으므로 전체 검사 공정의 열화 강건성을 입증하지는 않는다. 또한 주석 유도 정답과 단일 수집 자료에 한정되어 실제 불량 판별 성능으로 바로 일반화할 수 없다. 내부 검증까지 그룹을 분리하고, 촬영 시점・로트별 독립 자료와 현장 판정으로 재검증해야 한다.

Ⅳ. 결 론

볼 배치 검사에서 전처리 효과는 조건과 지표에 따라 달랐다. 가우시안 블러는 강한 잡음에서, CLAHE 는 잡음과 소량 학습의 복합 조건에서 엄격 정확도를 높였다. 전처리 선택은 판정 일치율뿐 아니라 누락・추가 검출, 반복 변동성 및 독립 평가를 함께 근거로 삼아야 한다.

참 고 문 헌

[1] G. Jocher, A. Chaurasia, and J. Qiu, “Ultralytics YOLOv8,” software, 2023.

[2] K. Zuiderveld, “Contrast Limited Adaptive Histogram Equalization,” Graphics Gems IV, pp. 474-485, 1994.

[3] E. Riba et al., “Kornia: an Open Source Differentiable Computer Vision Library for PyTorch,” arXiv:1910.02190, 2019.